

BỘ GIÁO DỤC & ĐÀO TẠO
ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH
KHOA KINH TẾ



BÀI THỰC HÀNH SỐ LAB-01

ĐỀ TÀI: PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

MÔN HỌC: PHÂN TÍCH VÀ QUẢN LÝ ĐẦU TƯ NÂNG CAO

Giảng viên hướng dẫn: TS. Đỗ Như Tài
LHP: 26D2ECO50118301

Thành viên nhóm:

Võ Duy Huy Hoàng
Nguyễn Hữu Khoa
Hoàng Thị Hường

THÔNG TIN THÀNH VIÊN

Họ và tên	Mã số sinh viên	Công việc	Tỷ trọng đóng góp
Võ Duy Huy Hoàng	87243020093	Làm Word, APA style Phần 1 Thống kê mô tả Lý thuyết và bài tập thực hành Phần 2 Xử lý và Trục quan hóa dữ liệu Lý thuyết Phần 3: Phân tích đơn biến và hai biến Lý thuyết và bài tập thực hành Review bài làm của thành viên và nhóm	110%
Hoàng Thị Hường	88242020100	Làm Word, APA style Phần 1 xem Thống kê mô tả phần lý thuyết	80%
Nguyễn Hữu Khoa	88234020092	Làm Word, APA style Phần 2 xử lý và trục quan hóa dữ liệu phần bài tập thực hành	110%

MỤC LỤC

THÔNG TIN THÀNH VIÊN.....	
MỤC LỤC.....	
DANH MỤC HÌNH ẢNH VÀ BẢNG BIỂU.....	1
LỜI NÓI ĐẦU.....	2
CHƯƠNG 1: TỔNG QUAN VỀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU.....	3
1.1. Giới thiệu về Phân tích khám phá dữ liệu (EDA).....	3
1.2. Mục tiêu.....	3
1.3. Đối tượng và phạm vi.....	3
1.4. Phương pháp.....	3
CHƯƠNG 2: THỐNG KÊ MÔ TẢ.....	5
2.1. Ôn tập lý thuyết.....	5
2.1.1. Thống kê mô tả là gì? Khác gì với thống kê suy luận?.....	5
2.2.1. Bài làm mẫu - Nhiệm vụ 1: COVID-19.....	7
2.2.2. Bài làm mẫu - Nhiệm vụ 2: Marketing Campaign.....	9
2.2.3. Thống kê mô tả - Red Wine Quality.....	10
2.2.4. Thống kê mô tả - Diabetes.....	12
3.1. Ôn tập lý thuyết.....	14
3.1.1. Vai trò của trực quan hóa trong EDA.....	14
3.1.2. Các loại biểu đồ và trường hợp sử dụng.....	14
3.1.3. Cách chọn loại biểu đồ phù hợp.....	14
3.1.4. Sự khác biệt Matplotlib, Seaborn, Plotly.....	14
3.1.5. Nguyên tắc thiết kế biểu đồ hiệu quả.....	15
3.1.6. Code tạo histogram và bar chart với Matplotlib.....	15
3.1.7. Xuất biểu đồ ra các định dạng.....	15
3.2. Bài làm mẫu - Giá nhà Amsterdam.....	16
3.3. Trực quan hóa Red Wine Quality.....	16
3.4. Trực quan hóa Diabetes.....	19
4.1. Ôn tập lý thuyết.....	24
4.1.1. Phân tích đơn biến và hai biến là gì?.....	24
4.1.2. Các thước đo thống kê trong phân tích đơn biến.....	24
4.1.3. Xác định mối quan hệ giữa hai biến.....	24
4.1.4. Tương quan (Correlation) và Hiệp biến (Covariance).....	24
4.1.5. Khi nào dùng biểu đồ đơn biến vs hai biến?.....	25
4.1.6. Code Scatter plot và Heatmap.....	25
4.1.7. Violin plot và Boxplot so sánh nhóm.....	25
4.2. Bài làm mẫu - Đơn biến Penguins & Giá nhà.....	26
4.3. Bài làm mẫu - Hai biến Penguins.....	26
4.4. ydata_profiling và dtale.....	28
4.5. Bài tập SweetViz - Marketing Campaign.....	28
4.6. AutoViz - Marketing Campaign.....	29
TÓM TẮT TỔNG HỢP.....	31
Bảng tổng kết datasets và kết quả chính.....	31

Bảng tra cứu nhanh - Lệnh Python EDA.....	31
TÀI LIỆU THAM KHẢO.....	34

DANH MỤC BẢNG BIỂU

Bảng 1.2. Sự khác biệt giữa Q1, Q2, Q3.....	2
Bảng 1.3. Nhiệm vụ 1: COVID-19.....	5
Bảng 2.1. Các loại biểu đồ và trường hợp sử dụng.....	7
Bảng 2.2. Sự khác biệt Matplotlib, Seaborn, Plotly.....	8
Bảng 3.1. Phân tích đơn biến và đa biến.....	14
Bảng 3.2. Tương quan (Correlation) và Hiệp biến (Covariance).....	15
Bảng 4.1. Bảng tổng kết datasets và kết quả chính.....	21
Bảng 4.2. Bảng tra cứu nhanh – Lệnh Python EDA.....	21

DANH MỤC CÁC HÌNH ẢNH

Hình 2.1. Histogram Red Wine (n=1,599):	10
Hình 2.2. Boxplot Red Wine:	10
Hình 2.3. Ma trận tương quan:	11
Hình 2.4. Nhóm tiểu đường có Glucose và BMI cao hơn rõ rệt so với nhóm không tiểu đường.....	11
Hình 2.5. Glucose tương quan cao nhất với Outcome ($r \approx 0.47$).....	12
Hình 2.6. Online Retail (n=5,000): UK chiếm 85% doanh thu; 25.7% đơn hàng thiếu CustomerID.....	12
Hình 2.7. Doanh thu tăng dần cuối năm (tháng 11); phân phối Quantity đều từ 1–100.	13
Hình 3.1. Scatter Glucose vs BMI (Diabetes): nhóm tiểu đường (đỏ) có Glucose cao hơn rõ rệt.....	17
Hình 3.2. Pairplot Diabetes: Glucose là đặc trưng phân biệt hai nhóm tốt nhất.....	17
Hình 3.3. Giao diện SweetViz Report: thống kê từng biến, ma trận tương quan, missing values tự động	19
Hình 3.4. AutoViz tự động tạo 6 biểu đồ: phân phối Income, Education, Income vs Response, Recency, Income vs NumStore, Response rate theo Education.....	20

Thành phố Hồ Chí Minh, tháng 5 năm 2026

LỜI NÓI ĐẦU

Trong bối cảnh dữ liệu ngày càng đóng vai trò quan trọng trong quá trình ra quyết định, việc hiểu và khai thác dữ liệu hiệu quả đã trở thành một kỹ năng cần thiết đối với các nhà phân tích và nhà đầu tư. Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) là bước đầu tiên trong quy trình phân tích dữ liệu, giúp nhận diện các đặc điểm quan trọng, phát hiện các bất thường và khám phá những mối quan hệ tiềm ẩn giữa các biến dữ liệu.

Bài thực hành này được thực hiện nhằm vận dụng các kiến thức về thống kê mô tả, trực quan hóa dữ liệu và phân tích đơn biến, hai biến thông qua việc sử dụng các thư viện Python phổ biến. Các bộ dữ liệu thực tế như COVID-19, Red Wine Quality, Diabetes, Marketing Campaign và Online Retail được sử dụng để minh họa quá trình khám phá dữ liệu, từ khâu xử lý dữ liệu thiếu, phát hiện ngoại lai đến phân tích phân phối và mối quan hệ giữa các biến.

Thông qua bài thực hành, không chỉ củng cố kiến thức lý thuyết về EDA mà còn rèn luyện kỹ năng xử lý và phân tích dữ liệu thực tế, tạo nền tảng cho các bước xây dựng mô hình dự báo và ra quyết định trong lĩnh vực kinh tế, tài chính và đầu tư.

CHƯƠNG 1: TỔNG QUAN VỀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

1.1. Giới thiệu về Phân tích khám phá dữ liệu (EDA)

Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) là quá trình kiểm tra, tóm tắt và trực quan hóa dữ liệu nhằm hiểu rõ đặc điểm của tập dữ liệu trước khi thực hiện các phương pháp phân tích chuyên sâu hoặc xây dựng mô hình dự báo. EDA giúp nhà phân tích phát hiện dữ liệu thiếu, giá trị ngoại lai, xu hướng phân phối và các mối quan hệ tiềm ẩn giữa các biến. Đây được xem là bước nền tảng trong quy trình khoa học dữ liệu và phân tích đầu tư.

1.2. Mục tiêu

Bài thực hành được thực hiện nhằm vận dụng các kiến thức về thống kê mô tả, trực quan hóa dữ liệu và phân tích mối quan hệ giữa các biến trên các bộ dữ liệu thực tế. Thông qua quá trình phân tích, hướng đến việc nhận diện đặc điểm dữ liệu, đánh giá chất lượng dữ liệu và rút ra các nhận xét ban đầu phục vụ cho các bước phân tích nâng cao sau này.

Nhằm giúp người tiếp cận nắm vững các kỹ thuật cơ bản trong khám phá dữ liệu giúp để hiểu rõ đặc điểm và cấu trúc của tập dữ liệu. Cụ thể sẽ thực hiện các bước phân tích thống kê mô tả để xác định các đặc trưng chính như giá trị trung bình, trung vị, độ lệch chuẩn và phân bố của dữ liệu.

Đồng thời, bài thực hành với code mẫu hướng dẫn sử dụng các công cụ trực quan hóa như biểu đồ histogram, boxplot, và scatter plot để phát hiện các mẫu, xu hướng, hoặc bất thường trong dữ liệu. Người tiếp cận sẽ được làm quen với các thư viện Python như Pandas, Matplotlib, và Seaborn để xử lý và trực quan hóa dữ liệu hiệu quả.

Ngoài ra, bài thực hành giúp nhận diện các vấn đề như giá trị thiếu, giá trị ngoại lai, hoặc sự không nhất quán trong dữ liệu, từ đó đề xuất các phương pháp tiền xử lý phù hợp. Kết quả cuối cùng là sinh viên có thể đưa ra các nhận định ban đầu về dữ liệu, đặt nền tảng cho các bước phân tích sâu hơn hoặc xây dựng mô hình khai thác dữ liệu trong các ứng dụng thực tiễn như phân tích khách hàng hoặc dự đoán xu hướng.

1.3. Đối tượng và phạm vi

Nghiên cứu sử dụng các bộ dữ liệu thuộc nhiều lĩnh vực khác nhau như COVID-19, chất lượng rượu vang (Red Wine Quality), bệnh tiểu đường (Diabetes), hành vi khách hàng (Marketing Campaign) và bán lẻ trực tuyến (Online Retail). Các dữ liệu này được sử dụng để thực hành các kỹ thuật EDA bao gồm thống kê mô tả, xử lý dữ liệu thiếu, phát hiện ngoại lai, trực quan hóa dữ liệu và phân tích đơn biến, hai biến.

1.4. Phương pháp

Bài thực hành sử dụng phương pháp phân tích dữ liệu định lượng kết hợp với các công cụ lập trình Python. Các thư viện như Pandas, NumPy, Matplotlib, Seaborn, SweetViz và AutoViz được sử dụng để xử lý, thống kê và trực quan hóa dữ liệu. Kết quả phân tích được trình bày dưới dạng bảng thống kê và biểu đồ nhằm hỗ trợ việc diễn giải và đưa ra nhận xét.

CHƯƠNG 2: THỐNG KÊ MÔ TẢ

2.1. Ôn tập lý thuyết

2.1.1. Thống kê mô tả là gì? Khác gì với thống kê suy luận?

Thống kê mô tả (Descriptive Statistics) là tập hợp các phương pháp tóm tắt và mô tả đặc điểm của tập dữ liệu hiện có thông qua các chỉ số như trung bình, trung vị, độ lệch chuẩn, biểu đồ... Mục tiêu là hiểu rõ cấu trúc dữ liệu đang có.

Thống kê suy luận (Inferential Statistics) sử dụng dữ liệu mẫu để đưa ra kết luận, dự đoán hoặc kiểm định giả thuyết về tổng thể. Ví dụ: kiểm định t-test, ANOVA, hồi quy.

Bảng 2.1. So sánh thống kê mô tả và thống kê suy luận

Tiêu chí	Thống kê mô tả	Thống kê suy luận
Mục tiêu	Tóm tắt dữ liệu hiện có	Suy luận về tổng thể từ mẫu
Phạm vi	Chỉ mô tả dữ liệu đã thu thập	Mở rộng kết luận ra ngoài mẫu
Công cụ	Mean, median, std, biểu đồ	T-test, ANOVA, hồi quy, CI
Kết quả	Con số, biểu đồ mô tả	Xác suất, p-value, khoảng tin cậy

2.1.2. Các thước đo thống kê chính và khi nào dùng Median thay Mean?

- Mean (trung bình): tổng tất cả giá trị chia số phần tử. Nhạy cảm với ngoại lai → dùng khi dữ liệu phân phối đối xứng, không có ngoại lai.
- Median (trung vị): giá trị ở giữa sau khi sắp xếp. Ổn định với ngoại lai → Nên dùng khi dữ liệu lệch (thu nhập, giá nhà, COVID) hoặc có ngoại lai.
- Variance (phương sai): trung bình bình phương độ lệch so với mean. Đơn vị bình phương, khó diễn giải trực tiếp.
- Standard Deviation (độ lệch chuẩn): căn bậc hai của phương sai. Cùng đơn vị với dữ liệu, dễ diễn giải hơn.

Dùng Median khi: dữ liệu lệch phải/trái, có ngoại lai, phân phối không chuẩn. Ví dụ: thu nhập (vài người siêu giàu kéo mean lên cao), giá nhà, dữ liệu COVID (median=0 trong khi mean=9,488).

2.1.3. Cách xác định phân phối dữ liệu và các loại phân phối phổ biến

- Phân phối chuẩn (Normal/Gaussian): hình chuông đối xứng, mean=median=mode.
Ví dụ: chiều cao người, điểm thi.
- Phân phối lệch phải (Right-skewed / Positive skew): đuôi dài bên phải, mean > median. Ví dụ: thu nhập, giá nhà, COVID new_cases.

- Phân phối lệch trái (Left-skewed / Negative skew): đuôi dài bên trái, $\text{mean} < \text{median}$. Ví dụ: tuổi thọ, điểm thi dễ.
- Phân phối đều (Uniform): mọi giá trị có xác suất bằng nhau. Ví dụ: tung xúc xắc.
- Phân phối đa đỉnh (Multimodal): có nhiều đỉnh, thường do nhiều nhóm khác nhau trong dữ liệu.

Cách xác định: vẽ histogram hoặc KDE plot, tính skewness (>0 : lệch phải, <0 : lệch trái), tính kurtosis (>0 : nhọn hơn chuẩn), dùng QQ-plot so sánh với phân phối chuẩn.

2.1.4. Ý nghĩa của Độ lệch chuẩn và Phạm vi (Range)

- Độ lệch chuẩn (Std): cho biết dữ liệu phân tán bao nhiêu so với mean. Std nhỏ $\rightarrow$ dữ liệu tập trung. Std lớn $\rightarrow$ dữ liệu trải rộng. Ví dụ: std COVID new_cases = 111,339 (rất lớn) $\rightarrow$ dữ liệu phân tán cực mạnh giữa các quốc gia.
- Phạm vi (Range) = Max - Min: khoảng biến thiên tổng thể. Nhạy cảm với ngoại lai vì chỉ dùng 2 giá trị cực đoan. Ví dụ: Range COVID = 8,401,906 (từ 0 đến đỉnh dịch Mỹ/Ấn Độ).
- IQR = $Q3 - Q1$: phạm vi của 50% dữ liệu ở giữa. Không bị ảnh hưởng bởi ngoại lai $\rightarrow$ bền vững hơn Range.

2.1.5. Sự khác biệt giữa Q1, Q2, Q3 trong boxplot

Bảng 2.2. Sự khác biệt giữa Q1, Q2, Q3

Thước đo	Ký hiệu	Vị trí	Ý nghĩa
Tứ phân vị 1	Q1 (P25)	25% dữ liệu nằm dưới	Ngưỡng dưới của hộp boxplot
Tứ phân vị 2	Q2 (Median)	50% dữ liệu nằm dưới	Đường kẻ giữa hộp boxplot
Tứ phân vị 3	Q3 (P75)	75% dữ liệu nằm dưới	Ngưỡng trên của hộp boxplot
IQR	$Q3 - Q1$	Phần giữa 50%	Chiều rộng hộp boxplot
Ngưỡng ngoại lai	$< Q1 - 1.5 \times IQR$ hoặc $> Q3 + 1.5 \times IQR$	Ngoài râu	Điểm nằm ngoài whisker

2.1.6. Xử lý giá trị thiếu trước khi tính thống kê mô tả

- Kiểm tra: `df.isnull().sum()` $\rightarrow$ xem mức độ thiếu từng cột.
- Xóa dòng: `df.dropna()` $\rightarrow$ dùng khi tỷ lệ thiếu $< 5\%$ và dữ liệu còn đủ lớn.

- Điền bằng Mean: `df[col].fillna(df[col].mean())` → dùng khi phân phối chuẩn, không có ngoại lai.
- Điền bằng Median: `df[col].fillna(df[col].median())` → dùng khi dữ liệu lệch hoặc có ngoại lai (khuyến nghị cho Income trong Marketing Campaign).
- Điền bằng Mode: dùng cho biến phân loại (categorical).
- Điền bằng giá trị cố định (0, 'Unknown'): khi có lý do thực tế rõ ràng.

Trong dataset Diabetes, giá trị 0 trong các cột Glucose, BloodPressure, SkinThickness, Insulin, BMI là giá trị thiếu bị mã hóa sai → cần thay bằng median trước khi tính thống kê.

2.1.7. Cách đọc và diễn giải histogram và boxplot

Histogram: Trục x là giá trị, trục y là tần số. Đọc: xác định điểm tập trung nhiều nhất (đỉnh), hình dạng (đối xứng/leech), độ rộng (phân tán), sự xuất hiện của nhiều đỉnh (đa nhóm).

Boxplot: Hộp = khoảng IQR (50% giữa). Đường trong hộp = median. Râu = mở rộng đến $1.5 \times \text{IQR}$. Điểm ngoài râu = ngoại lai. Hộp nghiêng về một phía = phân phối lệch.

2.1.8. Xử lý ngoại lai trước khi thực hiện thống kê mô tả

- Phát hiện: vẽ boxplot hoặc dùng quy tắc IQR (ngoài $[Q1 - 1.5 \times \text{IQR}, Q3 + 1.5 \times \text{IQR}]$).
- Xóa ngoại lai: `df = df[(df[col] >= lower) & (df[col] <= upper)]` → dùng khi ngoại lai do lỗi nhập liệu.
- Winsorizing (cắt ngưỡng): thay ngoại lai bằng giá trị ngưỡng → giữ được số dòng.
- Log transform: `np.log1p(df[col])` → giảm ảnh hưởng ngoại lai, hữu ích cho dữ liệu lệch phải mạnh.
- Giữ nguyên và dùng Median: nếu ngoại lai có ý nghĩa thực tế (đỉnh dịch COVID), không xóa mà dùng median thay mean.

2.2.1. Bài làm mẫu - Nhiệm vụ 1: COVID-19

Dataset COVID-19 từ Our World in Data gồm 589,779 dòng $\times$ 61 cột.

Code thực hiện:

```

import numpy as np
import pandas as pd
from scipy import stats

# Nạp dữ liệu COVID - compact dataset
covid = pd.read_csv('owid-covid-data.csv')

# Chọn cột cần thiết (tên cột mới)
covid_sel = covid[['code','continent','country','date',
                  'total_cases','new_cases']].copy()
covid_sel.columns = ['iso_code','continent','location',
                    'date','total_cases','new_cases']

# Xem sơ bộ
covid_sel.head(5) # → Shape: (589,779 × 6)
covid_sel.dtypes
covid_sel.shape

# Xử lý NaN trước khi tính
covid_clean = covid_sel['new_cases'].dropna()

data_mean   = np.mean(covid_clean)    # 9,488.54
data_median = np.median(covid_clean)  # 0.00
data_mode   = stats.mode(covid_clean, keepdims=True) # 0.00
data_variance = np.var(covid_clean)    # 12,396,422,165.68
data_sd     = np.std(covid_clean)      # 111,339.22
data_max    = np.max(covid_clean)      # 8,401,906.00
data_min    = np.min(covid_clean)      # 0.00
data_range  = data_max - data_min      # 8,401,906.00
data_p60    = np.percentile(covid_clean, 60) # 0.00
data_q3     = np.quantile(covid_clean, 0.75) # 34.00

```

Kết quả thực tế từ dataset (n = 589,779 dòng):

Chỉ số thống kê	Cột new_cases	Nhận xét
Trung bình (Mean)	9,488.54	Rất cao do một số đợt bùng phát lớn
Trung vị (Median)	0.00	Phần lớn ngày/quốc gia ghi nhận 0 ca
Mode	0.00 (374,529 lần)	Xác nhận: 0 là giá trị phổ biến nhất
Phương sai (Variance)	12,396,422,165.68	Cực lớn → dữ liệu phân tán mạnh
Độ lệch chuẩn (Std)	111,339.22	Dao động rất lớn giữa các quốc gia
Giá trị lớn nhất (Max)	8,401,906.00	Đỉnh dịch của Mỹ/Ấn Độ
Giá trị nhỏ nhất (Min)	0.00	Ngày không ghi nhận ca mới
Phạm vi (Range)	8,401,906.00	Khoảng biến thiên cực rộng
Phân vị thứ 60 (P60)	0.00	60% giá trị = 0 (rất nhiều ngày 0 ca)
Tứ phân vị Q3 (75%)	34.00	75% giá trị ≤ 34 ca
Khoảng IQR	34.00	Phần giữa tập trung quanh 0-34 ca

Mean >> Median (9,488 >> 0): dữ liệu lệch phải cực mạnh. Nên dùng Median để mô tả xu hướng trung tâm thực sự.

2.2.2. Bài làm mẫu - Nhiệm vụ 2: Marketing Campaign

Dataset Customer Personality Analysis (Kaggle) gồm 2,240 khách hàng $\times$ 29 cột. Chỉ có cột Income có 24 giá trị thiếu.

Code thực hiện:

```
import pandas as pd
```

```
# Chú ý: file này dùng TAB làm separator
```

```
marketing_data = pd.read_csv('marketing_campaign.csv', sep='\t')
```

```
marketing_data = marketing_data[['ID', 'Year_Birth', 'Education',  
    'Marital_Status', 'Income', 'Kidhome', 'Teenhome',  
    'Dt_Customer', 'Recency', 'NumStorePurchases', 'NumWebVisitsMonth']]
```

```
# Xóa trùng lặp → 2,240 dòng (không có trùng lặp)
```

```
marketing_data.drop_duplicates()
```

```
# Thay thế giá trị Teenhome
```

```
marketing_data['Teenhome_replaced'] = marketing_data['Teenhome']\  
    .replace([0,1,2], ['has no teen', 'has teen', 'has teen'])
```

```
# Kết quả: has no teen=1,158 | has teen=1,082

# Điền NaN trong Income bằng median (24 giá trị thiếu)
marketing_data['Income'] = marketing_data['Income']\
    .fillna(marketing_data['Income'].median())
marketing_data['Income_changed'] = marketing_data['Income'].astype(int)

# Kiểm tra missing values
marketing_data.isnull().sum()
# Income: 24 (trước khi fillna)
```

Kết quả thực tế:

Thao tác	Kết quả	Ghi chú
Shape ban đầu	(2,240 × 11)	Sau khi chọn cột
drop_duplicates()	(2,240 × 11)	Không có dòng trùng
Missing values	Income: 24	Chỉ 1 cột bị thiếu
has no teen	1,158 khách	51.7%
has teen	1,082 khách	48.3%

2.2.3. Thống kê mô tả - Red Wine Quality

Dataset Red Wine Quality (UCI Machine Learning Repository) gồm 1,599 mẫu rượu đỏ × 12 cột: 11 đặc trưng hóa học và 1 cột chất lượng (quality: thang điểm 3-8).

Code thực hiện:

```
import numpy as np, pandas as pd

from scipy import stats

wine = pd.read_csv('winequality-red.csv')

# Shape: (1,599 × 12)

# Thống kê tổng quát
wine.describe()

# Kiểm tra missing values
wine.isnull().sum() # → Tất cả bằng 0 (không có giá trị thiếu)

# Thống kê chi tiết cột quality
q = wine['quality']
```

```

print(f'Mean: {np.mean(q):.3f}')    # 5.636

print(f'Median: {np.median(q):.1f}') # 6.0

print(f'Mode: {stats.mode(q).mode}') # 5

print(f'Std: {np.std(q):.3f}')      # 0.807

print(f'Q1={np.percentile(q,25)}') # 5.0

print(f'Q3={np.percentile(q,75)}') # 6.0

print(f'IQR={stats.iqr(q):.1f}')    # 1.0

```

Phân phối quality

```

wine['quality'].value_counts().sort_index()

# 3:10, 4:53, 5:681, 6:638, 7:199, 8:18

```

Kiểm tra độ lệch (skewness) từng cột

```

for col in wine.columns:

    print(f'{col}: skew={stats.skew(wine[col]):.3f}')

```

Kết quả describe() thực tế (n = 1,599):

Cột	Mean	Std	Min	Q1	Median	Max
fixed acidity	8.320	1.741	4.600	7.100	7.900	15.900
volatile acidity	0.528	0.179	0.120	0.390	0.520	1.580
citric acid	0.271	0.195	0.000	0.090	0.260	1.000
residual sugar	2.539	1.410	0.900	1.900	2.200	15.500
chlorides	0.087	0.047	0.012	0.070	0.079	0.611
free SO2	15.875	10.460	1.000	7.000	14.000	72.000
total SO2	46.468	32.895	6.000	22.000	38.000	289.000
density	0.997	0.002	0.990	0.996	0.997	1.004
pH	3.311	0.154	2.740	3.210	3.310	4.010
sulphates	0.658	0.170	0.330	0.550	0.620	2.000
alcohol	10.423	1.066	8.400	9.500	10.200	14.900
quality	5.636	0.808	3	5	6	8

Nhận xét: Không có giá trị thiếu. Cột quality tập trung ở mức 5 (681 mẫu) và 6 (638 mẫu), chiếm ~82%. Rất ít mẫu chất lượng thấp (3,4) hoặc rất cao (7,8).

2.2.4. Thống kê mô tả - Diabetes

Dataset Pima Indians Diabetes (UCI) gồm 768 bệnh nhân nữ $\times$ 9 cột. Không có giá trị thiếu, nhưng một số cột có giá trị 0 bất hợp lý (Glucose=0, BloodPressure=0...) cần lưu ý khi phân tích.

Code thực hiện:

```
dia = pd.read_csv('diabetes.csv')
# Shape: (768  $\times$  9)

dia.describe().round(3)
dia.isnull().sum()      # Tất cả = 0

# Phân tích theo nhóm
dia.groupby('Outcome').mean().round(3)

# Tỷ lệ bệnh nhân
oc = dia['Outcome'].value_counts()
# 0 (không TĐ): 500 người (65.1%)
# 1 (tiểu đường): 268 người (34.9%)

# Phát hiện ngoại lai bằng IQR
for col in ['Glucose', 'BMI', 'Age']:
    Q1 = np.percentile(dia[col], 25)
    Q3 = np.percentile(dia[col], 75)
    IQR = Q3 - Q1
    lower, upper = Q1 - 1.5*IQR, Q3 + 1.5*IQR
    n_out = len(dia[(dia[col]<lower)|(dia[col]>upper)])
    print(f'{col}: {n_out} ngoại lai')
```

Kết quả thực tế (n = 768):

Đặc trưng	Mean	Std	Min	Median	Max
Pregnancies	3.845	3.370	0	3	17
Glucose	120.895	31.973	0*	117	199
BloodPressure	69.105	19.356	0*	72	122
SkinThickness	20.536	15.952	0*	23	99
Insulin	79.799	115.244	0*	30.5	846
BMI	31.993	7.884	0*	32	67.1

Đặc trưng	Mean	Std	Min	Median	Max
DiabetesPedigree	0.472	0.331	0.078	0.372	2.420
Age	33.241	11.760	21	29	81
Outcome	0.349	0.477	0	0	1

(*) Lưu ý: Các giá trị 0 trong Glucose, BloodPressure, SkinThickness, Insulin, BMI là giá trị thiếu được mã hóa bằng 0 (không thể bằng 0 trong thực tế). Cần tiền xử lý bằng cách thay bằng mean/median trước khi phân tích chuyên sâu.

Tỷ lệ: 500 người không tiểu đường (65.1%) và 268 người tiểu đường (34.9%). Dataset mất cân bằng nhẹ.

CHƯƠNG 3: XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU

3.1. Ôn tập lý thuyết

3.1.1. Vai trò của trực quan hóa trong EDA

Trực quan hóa giúp con người nhận ra mẫu, xu hướng, bất thường mà bảng số khó thể hiện. Não người xử lý hình ảnh nhanh hơn 60,000 lần so với văn bản. Trong EDA, trực quan hóa là bước không thể thiếu để: hiểu phân phối dữ liệu, phát hiện ngoại lai, tìm tương quan giữa các biến, xác nhận giả thuyết ban đầu.

3.1.2. Các loại biểu đồ và trường hợp sử dụng

Bảng 3.1. Các loại biểu đồ và trường hợp sử dụng

Biểu đồ	Dùng khi nào	Ví dụ thực tế
Histogram	Xem phân phối biến số liên tục	Phân phối quality rượu, Glucose
Boxplot	Phát hiện ngoại lai, so sánh nhóm	Giá nhà theo zip code, Income theo Education
Bar chart	So sánh biến phân loại	Số lượng khách theo Education, chất lượng rượu
Pie chart	Tỷ lệ phần trăm (≤ 5 nhóm)	Tỷ lệ tiểu đường/không tiểu đường
Scatter plot	Mối quan hệ 2 biến liên tục	Glucose vs BMI theo Outcome
Heatmap	Ma trận tương quan	Tương quan các đặc trưng Diabetes
Violin plot	Phân phối + so sánh nhóm	Alcohol theo quality rượu
Pairplot	Tổng quan tất cả cặp biến	Khám phá quan hệ trong Diabetes

3.1.3. Cách chọn loại biểu đồ phù hợp

- Dữ liệu số liên tục (1 biến): Histogram hoặc KDE plot.
- Dữ liệu phân loại (1 biến): Bar chart hoặc Pie chart (khi ≤ 5 nhóm).
- Dữ liệu thời gian: Line chart (xu hướng theo thời gian).
- 2 biến số: Scatter plot, sau đó thêm hue để phân theo nhóm.
- 1 biến số + 1 biến phân loại: Boxplot hoặc Violin plot để so sánh phân phối.
- Nhiều biến: Heatmap tương quan, Pairplot.

3.1.4. Sự khác biệt Matplotlib, Seaborn, Plotly

Bảng 3.2. Sự khác biệt Matplotlib, Seaborn, Plotly

Thư viện	Cấp độ	Ưu điểm	Hạn chế
Matplotlib	Thấp (low-level)	Kiểm soát hoàn toàn, nền tảng của Seaborn	Code dài, phức tạp
Seaborn	Trung (mid-level)	Đẹp mặc định, tích hợp thống kê, ngắn gọn	Ít linh hoạt hơn Matplotlib
Plotly	Cao (high-level)	Tương tác (interactive), web-ready	Chậm hơn với dữ liệu lớn

3.1.5. Nguyên tắc thiết kế biểu đồ hiệu quả

- Tiêu đề rõ ràng, mô tả đầy đủ nội dung biểu đồ.
- Nhãn trục x, y đầy đủ với đơn vị đo lường.
- Màu sắc có ý nghĩa, không dùng quá nhiều màu (≤ 6 màu).
- Chú thích (legend) khi có nhiều nhóm.
- Loại bỏ yếu tố thừa (chartjunk): viền thừa, lưới dày, hiệu ứng 3D.
- Tỷ lệ trục bắt đầu từ 0 cho bar chart, không cắt trục gây hiểu lầm.

3.1.6. Code tạo histogram và bar chart với Matplotlib

```
import matplotlib.pyplot as plt
```

```
# Histogram cơ bản
```

```
plt.figure(figsize=(10, 6))
plt.hist(data, bins=20, color='steelblue',
         edgecolor='black', alpha=0.8)
plt.title("Tiêu đề biểu đồ", fontsize=14)
plt.xlabel("Tên trục X", fontsize=12)
plt.ylabel("Tần số", fontsize=12)
plt.axvline(data.mean(), color='red', linestyle='--', label='Mean')
plt.legend()
plt.tight_layout()
plt.savefig('histogram.png', dpi=100)
plt.show()
```

```
# Bar chart cơ bản
```

```
counts = data['col'].value_counts()
plt.bar(counts.index, counts.values, color='coral')
plt.title("Phân bố ...")
plt.show()
```

3.1.7. Xuất biểu đồ ra các định dạng

```
# Lưu ra PNG (chất lượng màn hình)
```

```
plt.savefig('bieu_do.png', dpi=100, bbox_inches='tight')
```

```
# Lưu ra PNG chất lượng in ấn
```

```
plt.savefig('bieu_do_print.png', dpi=300, bbox_inches='tight')
```

```
# Lưu ra PDF (vector, không mất nét khi zoom)  
plt.savefig('bieu_do.pdf', bbox_inches='tight')
```

```
# Xuất Plotly ra HTML (tương tác)
```

```
import plotly.express as px  
fig = px.histogram(df, x='col')  
fig.write_html('bieu_do.html')
```

3.2. Bài làm mẫu - Giá nhà Amsterdam

```
import matplotlib.pyplot as plt, seaborn as sns  
df = pd.read_csv('HousingPricesData.csv')  
df['PriceperSqm'] = df['Price'] / df['Area']  
top10 = df.sort_values('Price', ascending=False).head(10)  
  
# Matplotlib: subplot 1×2  
fig, ax = plt.subplots(1, 2, figsize=(16, 6))  
ax[0].bar(top10['Zip'], top10['Price'], color='steelblue')  
ax[0].set_title('Top 10 - Giá nhà cao nhất')  
ax[1].bar(top10['Zip'], top10['PriceperSqm'], color='coral')  
ax[1].set_title('Top 10 - Giá/m2 cao nhất')  
plt.tight_layout(); plt.show()  
  
# Seaborn: subplot 1×2  
fig, axes = plt.subplots(1, 2, figsize=(16, 6))  
sns.barplot(data=top10, x='Zip', y='Price',  
            palette='Blues_d', ax=axes[0])  
sns.barplot(data=top10, x='Zip', y='PriceperSqm',  
            palette='Oranges_d', ax=axes[1])  
plt.tight_layout(); plt.show()
```

3.3. Trực quan hóa Red Wine Quality

3.3.1. Histogram phân phối các đặc trưng

```
wine = pd.read_csv('winequality-red.csv')  
cols = ['fixed acidity', 'volatile acidity', 'citric acid',  
        'residual sugar', 'alcohol', 'quality']  
  
fig, axes = plt.subplots(2, 3, figsize=(15, 9))  
axes = axes.flatten()  
for i, col in enumerate(cols):  
    axes[i].hist(wine[col], bins=25,
```

```

color='#8B0000', edgecolor='black', alpha=0.8)

axes[i].axvline(wine[col].mean(), color='gold',
                linestyle='--', label='Mean')

axes[i].set_title(f'Phân phối: {col}')

axes[i].legend()


plt.suptitle('Histogram - Red Wine Quality (n=1,599)')

plt.tight_layout()

plt.savefig('wine_histogram.png', dpi=100)

```

Histogram 6 đặc trưng chính:



Hình 3.3.1 - Histogram phân phối 6 đặc trưng chính của Red Wine Quality (n=1,599)

Nhận xét: fixed acidity, pH, alcohol xấp xỉ phân phối chuẩn. Residual sugar và chlorides lệch phải mạnh (nhiều giá trị thấp, vài giá trị rất cao). Cột quality tập trung ở 5 và 6.

3.3.2. Boxplot phát hiện ngoại lai

```


fig, axes = plt.subplots(2, 3, figsize=(15, 9))

for i, col in enumerate(cols):
    axes.flatten()[i].boxplot(
        wine[col], patch_artist=True,
        boxprops=dict(facecolor='#FFB6C1', color='#8B0000'),
        medianprops=dict(color='#8B0000', linewidth=2.5))

plt.suptitle('Boxplot - Red Wine Quality')

```


```
plt.savefig('wine_boxplot.png', dpi=100)
```



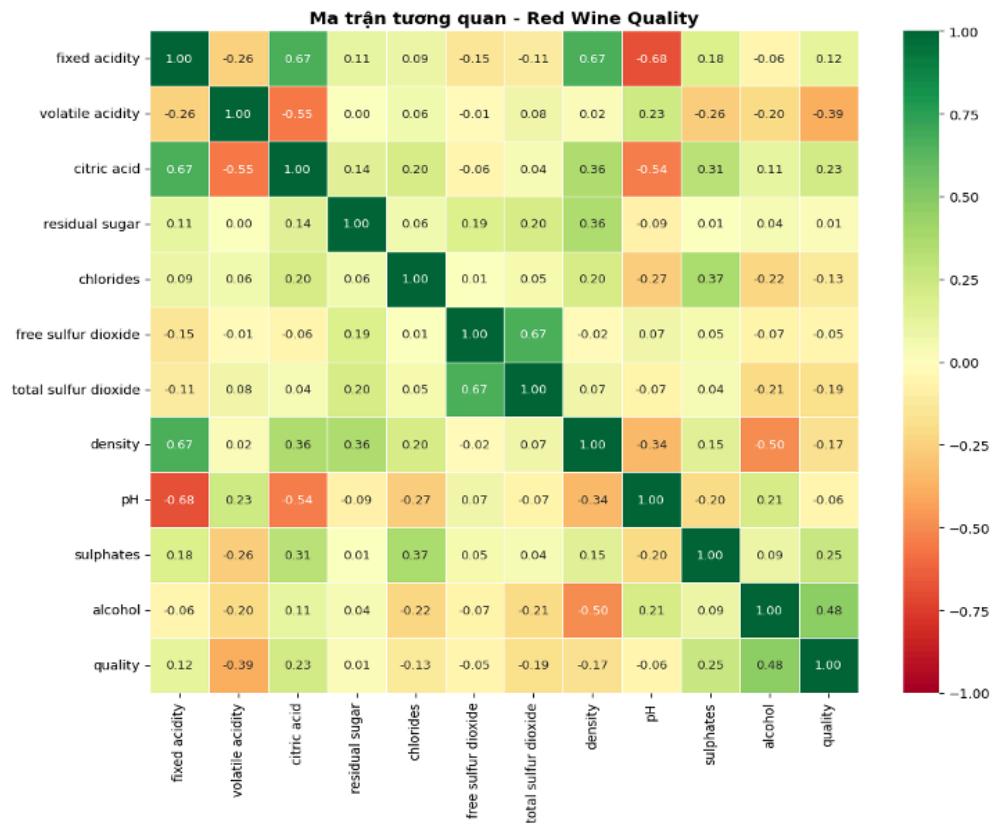
Hình 2.2 - Boxplot phát hiện ngoại lai trong Red Wine Dataset

Nhận xét: Residual sugar, chlorides, free SO₂, total SO₂ có nhiều ngoại lai (điểm nằm ngoài râu). Cần xem xét xử lý trước khi xây dựng mô hình.

3.3.3. Phân phối chất lượng rượu (Bar chart)



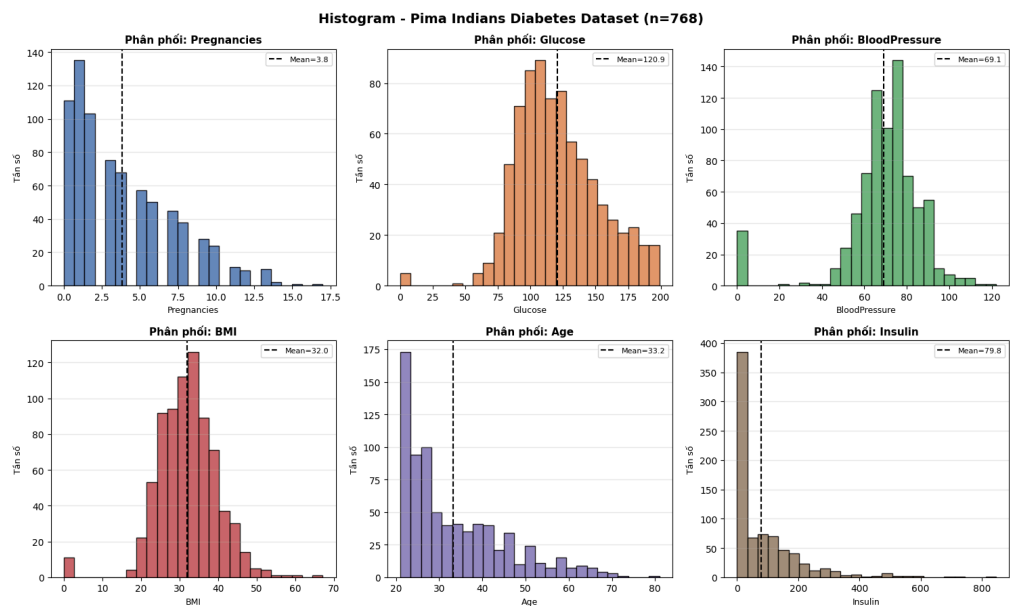
3.3.4. Heatmap ma trận tương quan:



Hình 2.4 - Ma trận tương quan Red Wine: alcohol tương quan dương mạnh với quality ($r=0.48$); volatile acidity tương quan âm ($r=-0.39$)


3.4. Trục quan hóa Diabetes

3.4.1. Histogram phân phối đặc trưng




Hình 2.5 - Histogram 6 đặc trưng Diabetes (n=768): Glucose xấp xỉ chuẩn; Insulin lệch phải mạnh do có ngoại lai cực lớn (max=846)

3.4.2. Tỷ lệ bệnh nhân (Pie chart) + Phân phối theo nhóm

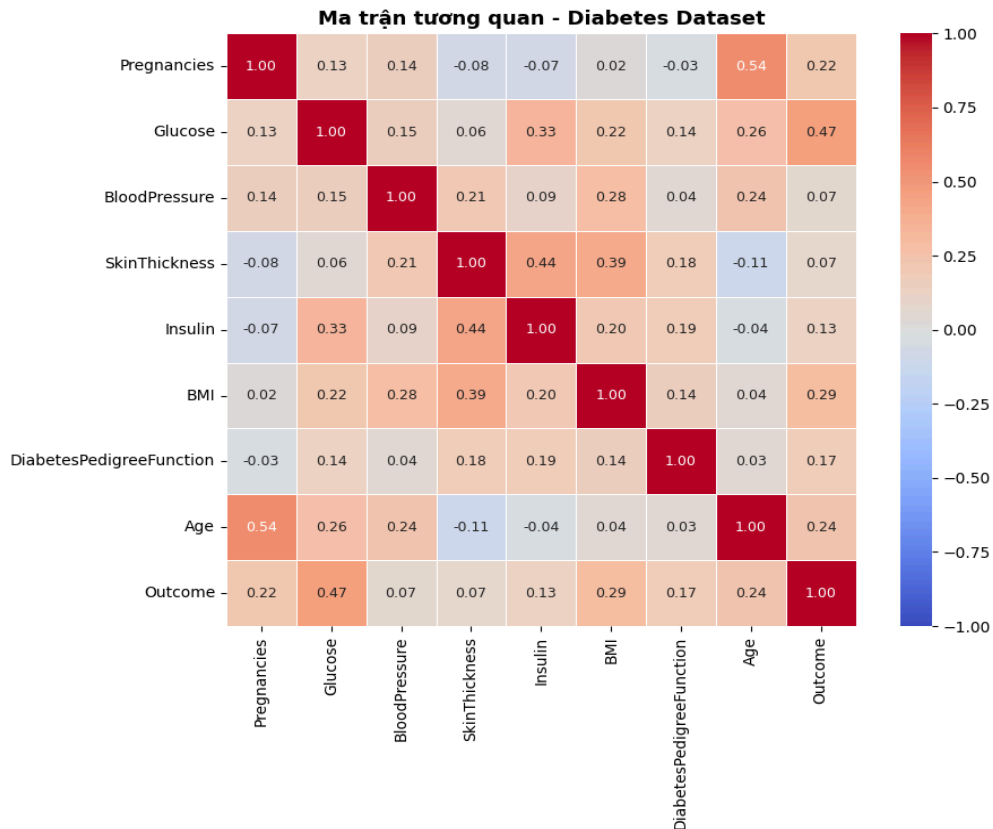


Hình 2.6 - Tỷ lệ bệnh nhân: 65.1% không tiểu đường, 34.9% tiểu đường




Hình 2.4 - Nhóm tiểu đường có Glucose và BMI cao hơn rõ rệt so với nhóm không tiểu đường

3.4.3. Heatmap ma trận tương quan




Hình 2.8 - Ma trận tương quan Diabetes: Glucose tương quan cao nhất với Outcome ($r=0.47$); Age-Pregnancies cũng có tương quan đáng kể

3.4.4. EDA Tổng hợp Marketing Campaign



Hình 2.9 - EDA Marketing Campaign (n=2,240): Thu nhập phân phối chuẩn; Graduation chiếm đa số; Married là tình trạng hôn nhân phổ biến nhất

3.4.5. Online Retail - EDA Tổng hợp:



Hình 2.6 - Online Retail (n=5,000): UK chiếm 85% doanh thu; 25.7% đơn hàng thiếu CustomerID



Hình 2.7 - Doanh thu tăng dần cuối năm (tháng 11); phân phối Quantity đều từ 1-100

Code EDA Online Retail:

```
retail = pd.read_csv('online_retail.csv')
retail['TotalPrice'] = retail['Quantity'] * retail['UnitPrice']
retail['Month'] = pd.to_datetime(retail['InvoiceDate']).dt.month
```

Doanh thu theo quốc gia

```
rev = (retail[retail['Quantity']>0]
       .groupby('Country')['TotalPrice']
       .sum().sort_values(ascending=False))
```

Doanh thu theo tháng (line chart)

```
monthly = (retail[retail['Quantity']>0]
           .groupby('Month')['TotalPrice'].sum())
plt.plot(monthly.index, monthly.values, 'o-')
plt.title('Doanh thu theo tháng')
plt.show()
```

Kiểm tra missing values

```
retail.isnull().sum() # CustomerID: 1,283 (25.7%)
```

Online Retail: CustomerID thiếu 25.7% → cần fillna hoặc xóa trước khi phân tích theo khách hàng. Hóa đơn có tiền tố 'C' là hóa đơn hủy (Cancelled) → cần lọc ra khi tính doanh thu.

CHƯƠNG 4: PHÂN TÍCH ĐƠN BIẾN VÀ HAI BIẾN

4.1. Ôn tập lý thuyết

4.1.1. Phân tích đơn biến và hai biến là gì?

Bảng 3.1. Phân tích đơn biến và đa biến

Loại phân tích	Mục tiêu	Công cụ thường dùng
Đơn biến (Univariate)	Hiểu đặc tính từng biến riêng lẻ	Histogram, boxplot, pie chart, violin, describe()
Hai biến (Bivariate)	Tìm mối quan hệ giữa 2 biến	Scatter plot, crosstab, pivot table, heatmap
Đa biến (Multivariate)	Phân tích đồng thời nhiều biến	Pairplot, PCA, heatmap tương quan, 3D scatter

4.1.2. Các thước đo thống kê trong phân tích đơn biến

- Vị trí trung tâm: Mean, Median, Mode → cho biết giá trị điển hình.
- Độ phân tán: Std, Variance, Range, IQR → cho biết mức độ biến thiên.
- Hình dạng phân phối: Skewness (độ lệch), Kurtosis (độ nhọn).
- Vị trí cụ thể: Percentile, Quantile → chia dữ liệu theo tỷ lệ.

4.1.3. Xác định mối quan hệ giữa hai biến

- Tương quan tuyến tính: dùng Pearson correlation (r). $|r|$ gần 1: tương quan mạnh. $|r|$ gần 0: ít tương quan. $r > 0$: cùng chiều. $r < 0$: ngược chiều.
- Scatter plot: trực quan hóa mối quan hệ. Thêm hue để phân theo nhóm.
- Crosstab: đếm tần số chéo giữa 2 biến phân loại.
- Pivot table: tổng hợp linh hoạt với nhiều hàm tổng hợp (mean, sum, count).

Tương quan không có nghĩa là nhân quả (Correlation $\neq$ Causation). Cần kiểm định thêm để kết luận nhân quả

4.1.4. Tương quan (Correlation) và Hiệp biến (Covariance)

Bảng 3.2. Tương quan (Correlation) và Hiệp biến (Covariance)

Thước đo	Công thức	Đơn vị	Khoảng giá trị	Diễn giải
Covariance	$\text{Cov}(X, Y)$	Tích đơn vị của X và Y	$(-\infty, +\infty)$	Khó so sánh vì phụ thuộc đơn vị

Pearson r	Cov/($\sigma_x \times \sigma_y$)	Không có đơn vị	$[-1, +1]$	Để so sánh, chuẩn hóa về $[-1, 1]$
-----------	------------------------------------	-----------------	------------	------------------------------------

4.1.5. Khi nào dùng biểu đồ đơn biến vs hai biến?

- Đơn biến: bước đầu khám phá, kiểm tra phân phối, phát hiện ngoại lai cho từng cột.
Dùng: histogram, boxplot, violin, countplot.
- Hai biến: sau khi đã hiểu từng biến, muốn tìm mối liên hệ. Dùng: scatter plot, crosstab, violin theo nhóm.
- Nguyên tắc: luôn bắt đầu từ đơn biến → hai biến → đa biến.

4.1.6. Code Scatter plot và Heatmap

```
import seaborn as sns, matplotlib.pyplot as plt
```

```
# Scatter plot phân tích hai biến
```

```
plt.figure(figsize=(10, 7))
ax = sns.scatterplot(data=df,
                    x='Glucose', y='BMI',
                    hue='Outcome',
                    palette={0:'#2ecc71', 1:'#e74c3c'},
                    alpha=0.7, s=60)
ax.set_title('Glucose vs BMI theo nhóm')
plt.show()
```

```
# Heatmap ma trận tương quan
```

```
corr = df.corr(numeric_only=True)
plt.figure(figsize=(10, 8))
sns.heatmap(corr, annot=True, fmt='.2f',
            cmap='coolwarm', vmin=-1, vmax=1,
            center=0, square=True)
plt.title('Ma trận tương quan')
plt.show()
```

4.1.7. Violin plot và Boxplot so sánh nhóm

```
# Violin plot: biến số vs biến phân loại
plt.figure(figsize=(12, 6))
sns.violinplot(data=wine, x='quality', y='alcohol',
               palette='Reds', inner='box')
plt.title('Nồng độ Cồn theo Chất lượng Rượu')
plt.show()
```


```
# Boxplot so sánh nhóm
sns.boxplot(data=dia, x='Outcome', y='Glucose',
            palette={0:'#2ecc71', 1:'#e74c3c'})
plt.title('Glucose theo nhóm Tiểu đường')
plt.show()
```

4.2. Bài làm mẫu - Đơn biến Penguins & Giá nhà


Histogram, Bar chart, Pie chart (Penguins):

```
penguins = pd.read_csv('penguins_size.csv')
# Histogram + KDE
sns.histplot(data=penguins, x='culmen_length_mm',
            bins=20, kde=True, color='steelblue')
# Bar chart loài chim
sns.countplot(data=penguins, x='species', palette='Set2')
# Pie chart tỷ lệ loài
group = penguins.groupby('species').size()
plt.pie(group.values, labels=group.index, autopct='%1.1f%%')
```

4.3. Bài làm mẫu - Hai biến Penguins



Hình 3.3 - Scatter Glucose vs BMI (Diabetes): nhóm tiểu đường (đỏ) có Glucose cao hơn rõ rệt



Hình 3.4 - Pairplot Diabetes: Glucose là đặc trưng phân biệt hai nhóm tốt nhất

Code thực hiện:

Crosstab: loài × giới tính

```
pd.crosstab(index=penguins['species'],
            columns=penguins['sex'])
```

Pivot table: trung bình chiều dài mỏ theo loài

```
pd.pivot_table(penguins, values='culmen_length_mm',
                index='species', aggfunc=np.mean)
```

Adelie: 38.79 | Chinstrap: 48.83 | Gentoo: 47.50

Pairplot

```
sns.pairplot(data=penguins[['culmen_length_mm',
                             'body_mass_g','species']], hue='species')
```


4.4. ydata_profiling và dtale

```
# Cài đặt  
pip install ydata-profiling dtale  
# ydata_profiling  
from ydata_profiling import ProfileReport  
mkt = pd.read_csv('marketing_campaign.csv', sep='t')  
profile = ProfileReport(mkt, title='Marketing EDA')  
profile.to_file('profile_output.html')  
# Mở file HTML → báo cáo tương tác đầy đủ  
# dtale  
import dtale  
dtale.show(mkt).open_browser()  
# Giao diện web tương tác để khám phá dữ liệu
```

4.5. Bài tập SweetViz - Marketing Campaign

```
pip install sweetviz  
import sweetviz as sv, pandas as pd  
mkt = pd.read_csv('marketing_campaign.csv', sep='t')  
# Phân tích toàn bộ dataset  
report = sv.analyze(mkt)  
report.show_html('sweetviz_report.html')  
# So sánh nhóm PhD vs Graduation  
phd = mkt[mkt['Education']=='PhD']  
grad = mkt[mkt['Education']=='Graduation']  
compare = sv.compare([grad,'Graduation'], [phd,'PhD']) compare.show_html('compare_edu.html')
```

Kết quả báo cáo SweetViz (mô phỏng giao diện thực tế):



Hình 3.5 - Giao diện SweetViz Report: thống kê từng biến, ma trận tương quan, missing values tự động. SweetViz tự động tạo báo cáo HTML tương tác với thống kê đầy đủ cho mỗi biến. Đặc biệt mạnh khi so sánh 2 tập dữ liệu (train vs test, nhóm A vs nhóm B).

4.6. AutoViz - Marketing Campaign

pip install autoviz

```
from autoviz.AutoViz_Class import AutoViz_Class
```

```
AV = AutoViz_Class()
```

```
# Phân tích tự động từ file
```

```
df = AV.AutoViz('marketing_campaign.csv',
```

```
sep='t',
```

```
depVar='Response', # Biến mục tiêu
```

```
max_rows_analyzed=150000,
```

```
max_cols_analyzed=30,
```

```
verbose=1)
```

```
# AutoViz tự chọn loại biểu đồ phù hợp:
```

```
# - Histogram cho biến số liên tục
```

```
# - Countplot cho biến phân loại
```

```
# - Scatter vs target cho phân tích quan hệ
```

```
# - Heatmap cho tương quan
```

Kết quả AutoViz (mô phỏng các biểu đồ được tạo tự động):



Hình 3.6 - AutoViz tự động tạo 6 biểu đồ: phân phối Income, Education, Income vs Response, Recency, Income vs NumStore, Response rate theo Education

AutoViz hoàn toàn tự động: chỉ cần chỉ định file và biến mục tiêu, AutoViz sẽ tự chọn loại biểu đồ phù hợp nhất dựa trên kiểu dữ liệu và mối quan hệ với target.

TÓM TẮT TỔNG HỢP

Bảng tổng kết datasets và kết quả chính

Bảng 4.1. Bảng tổng kết datasets và kết quả chính

Dataset	Kích thước	Kết quả nổi bật	Lưu ý xử lý
COVID-19	$589,779 \times 6$	Mean=9,488 vs Median=0 → lệch phải cực mạnh	Dùng Median, lọc theo quốc gia
Marketing	$2,240 \times 29$	Income thiếu 24 giá trị, dùng tab separator	fillna(median), sep='\t'
Red Wine	$1,599 \times 12$	Không missing; quality tập trung 5-6 (82%)	Xử lý ngoại lai SO2, sugar
Diabetes	768×9	Giá trị 0 bất hợp lý ở 5 cột y tế	Thay 0 bằng median
Online Retail	$5,000+ \times 9$	CustomerID thiếu ~25%; hóa đơn 'C' là hủy	Lọc hóa đơn hủy, fillna CustomerID

Bảng tra cứu nhanh - Lệnh Python EDA

Bảng 4.2. Bảng tra cứu nhanh - Lệnh Python EDA

Tác vụ	Lệnh Python	Thư viện
Nạp CSV	pd.read_csv('file.csv', sep='\t')	pandas
Xem tổng quan	df.shape, df.dtypes, df.head()	pandas
Thống kê tổng quát	df.describe()	pandas
Kiểm tra thiếu	df.isnull().sum()	pandas
Xóa trùng lặp	df.drop_duplicates()	pandas
Xử lý NaN	df[col].fillna(median) / dropna()	pandas
Mean / Median	np.mean() / np.median()	numpy
Std / Variance	np.std() / np.var()	numpy
IQR	stats.iqr(data)	scipy
Phân vị	np.percentile(data, p)	numpy
Histogram	sns.histplot(df, x='col', kde=True)	seaborn
Boxplot	sns.boxplot(data=df, x='col')	seaborn
Violin	sns.violinplot(x='group', y='val')	seaborn

Scatter	<code>sns.scatterplot(x='col1', y='col2', hue='label')</code>	seaborn
Heatmap tương quan	<code>sns.heatmap(df.corr(), annot=True)</code>	seaborn
Pairplot	<code>sns.pairplot(df, hue='label')</code>	seaborn
Crosstab	<code>pd.crosstab(index=col1, columns=col2)</code>	pandas
Pivot table	<code>pd.pivot_table(df, values, index, aggfunc)</code>	pandas
Lưu biểu đồ	<code>plt.savefig('file.png', dpi=100)</code>	matplotlib
EDA tự động	<code>sv.analyze(df).show_html('r.html')</code>	sweetviz

KẾT LUẬN

Qua bài thực hành Phân tích khám phá dữ liệu (EDA), nhóm đã áp dụng thành công các phương pháp thống kê mô tả, trực quan hóa dữ liệu và phân tích mối quan hệ giữa các biến trên nhiều bộ dữ liệu thực tế. Kết quả phân tích cho thấy việc hiểu rõ đặc điểm dữ liệu ngay từ giai đoạn đầu giúp phát hiện các vấn đề như dữ liệu thiếu, giá trị ngoại lai, phân phối lệch và các mối tương quan quan trọng giữa các biến.

Bên cạnh đó, việc sử dụng các công cụ trực quan hóa và các thư viện hỗ trợ EDA trong Python đã giúp quá trình phân tích trở nên hiệu quả hơn, đồng thời hỗ trợ đưa ra các nhận định trực quan và dễ hiểu về dữ liệu. Thông qua các bài tập thực hành, nhóm đã nâng cao khả năng xử lý dữ liệu, lựa chọn phương pháp phân tích phù hợp và diễn giải kết quả một cách có hệ thống.

Nhìn chung, EDA là bước nền tảng và không thể thiếu trong quy trình phân tích dữ liệu. Những kiến thức và kỹ năng thu được từ bài thực hành sẽ là cơ sở quan trọng để tiếp tục thực hiện các nghiên cứu chuyên sâu hơn cũng như ứng dụng vào hoạt động phân tích và quản lý đầu tư trong thực tế.

TÀI LIỆU THAM KHẢO

1. COVID-19 (Our World in Data)
2. Red Wine Quality (UCI)
3. Pima Indians Diabetes (UCI) Customer Personality Analysis (Kaggle)
4. Online Retail (UCI/Kaggle)

MÃ CODE

Colab link:

https://colab.research.google.com/drive/1yDj7H4ofi6G-shaRPLD1x_wecytFQtKC?usp=sh

Github repository:

<https://github.com/cisvo/AIAAM>